

Таргетированные состязательные атаки на детекторы синтетических изображений

Отчёт по результатам кампании

4 сентября 2026 г.

1. Задача

Проверялось, можно ли незаметным изменением пикселей заставить детектор дипфейков ошибиться, и переносится ли такая атака на другой детектор, который она не видела.

Второй вопрос главный. Атака, работающая только против той модели, по которой она строилась, говорит о слабости конкретной сети. Атака, переносимая между моделями разной архитектуры, указывает на общую уязвимость.

2. Постановка

Два детектора: **ViT-B/16** работает с пространственным RGB-изображением, **DenseNet121-DCT** — с частотным представлением.

Каждый детектор выступал в двух ролях. *Источник* — модель, по градиенту которой строится возмущение. *Цель* — модель, на которой проверяется результат. Совпадение ролей даёт белый ящик, различие — перенос.

Данные: 100 поддельных изображений из TEST/TEST_FAKE набора CelebA, замороженный манифест с контролем хеша. Направление атаки — fake→real, то есть подделку заставляют выглядеть настоящей.

Ограничение возмущения: $L_\infty \leq 8/255$, проверяется по пересчитанному с диска PNG. Сид 0 во всех прогонах.

Метрики: **ASR** — доля успеха, где знаменатель это изображения, классифицированные детектором верно до атаки; **SSIM** и **LPIPS** — сохранность изображения.

3. Атаки

Шесть методов, от простого к сложному.

Метод	Суть
FGSM	Один шаг по знаку градиента на весь бюджет.
PGD	Десять малых шагов со случайным стартом и проекцией после каждого.
MI-DI-FGSM	PGD плюс momentum и случайное изменение размера входа.
Ensemble MI + EoT	Momentum по обоим детекторам, усреднение по искажениям.
SSA / S ² I-FGSM	Усреднение градиентов по 20 случайно зашумлённым спектрам.
MIG-COW	Интегрированные градиенты с консенсусным взвешиванием.

4. Результаты

Двенадцать прогонов, по 100 изображений каждый. Все прошли детерминированную верификацию, нарушений бюджета ноль.

Метод	Источник	Бел. ящик	Перенос	SSIM	LPIPS	c
FGSM	ViT	0.010	0.010	0.864	0.303	178
FGSM	DCT	0.160	0.000	0.921	0.099	177
PGD	ViT	0.780	0.040	0.848	0.211	182
PGD	DCT	0.250	0.000	0.815	0.197	154
MI-DI-FGSM	ViT	0.130	0.010	0.907	0.246	167
MI-DI-FGSM	DCT	0.140	0.000	0.935	0.100	205
Ensemble MI + EoT	ViT	0.280	0.020	0.914	0.234	252
Ensemble MI + EoT	DCT	0.240	0.000	0.948	0.077	274
MIG-COW	ViT	0.720	0.010	0.907	0.241	581
MIG-COW	DCT	0.290	0.000	0.952	0.072	432
SSA	ViT	0.870	0.040	0.890	0.273	662
SSA	DCT	0.320	0.000	0.765	0.375	985

Матрица переноса

Строки — источник градиента, столбцы — где измеряли. Приведён лучший результат по каждой клетке.

	ViT	DCT
ViT (источник)	0.870	0.040
DCT (источник)	0.000	0.320

5. Выводы

Перенос отсутствует. Это главный результат. Лучшее значение вне диагонали — 0.040, то есть четыре изображения из ста, и достигается оно двумя разными методами. В направлении DCT→ViT перенос ровно нулевой у всех шести атак без исключения.

Ни один метод не изменил картину, включая те, что специально проектировались ради переносимости: momentum и диверсификация входа в MI-DI, усреднение по спектрам в SSA, ансамблирование и консенсус в MIG-COW. Пространственный и частотный детекторы, судя по этим данным, не разделяют эксплуатируемых уязвимостей.

SSA сильнейшая в белом ящике — 0.870 против ViT и 0.320 против DCT, лучший результат в обоих направлениях. Работа в частотной области помогает атаковать, но не переносить.

Атака через DCT слабее. При одинаковом бюджете белый ящик по частотному детектору держится в диапазоне 0.14–0.32 против 0.01–0.87 по пространственному. Вероятная причина в том, что градиент проходит через перевод в градации серого, масштабирование, обрезку до 128×128 и DCT, теряя большую часть пути к пикселям.

FGSM практически не работает — 0.010 в белом ящике при худшем качестве изображения. Один грубый шаг на весь бюджет промахивается там, где десять малых с проекцией попадают.

6. Оговорки

MI-DI-FGSM ведёт себя аномально. Метод есть PGD с добавленными momentum и диверсификацией, то есть должен быть не слабее. Фактически 0.130 против 0.780 у PGD, в шесть раз хуже. Это

указывает на дефект реализации, вероятнее всего в нормировке градиента перед накоплением момента, а не на свойство метода. Строку следует считать недостоверной до перепроверки.

Ансамблевые методы вырождены. При двух детекторах схема leave-one-detector-out оставляет один источник. Ensemble MI + EoT и MIG-COW запускались, но их результаты нельзя читать как ансамблевые.

Конфаунд по формату файлов. В наборе данных все настоящие изображения хранятся в JPG, все поддельные — в PNG. Метку можно предсказать по расширению файла, не анализируя пиксели. Чистая точность обоих детекторов равна 1.000, и она может отражать различие в сжатии, а не способность распознавать подделку. Это ограничение самого набора данных.

Отложенной выборки нет. Все методы сравнивались на одних и тех же 100 изображениях, на них же приведены результаты. Параметры атак задавались заранее в спецификациях и не подбирались по ответам детекторов, что ограничивает подгонку, но строгое утверждение об обобщении требует пересечения набора.

Матрица неполна по детекторам. Веса детекторов NPR и AIDE доступны, но адаптеры не написаны. С двумя моделями перенос измеряется единственной парой.

7. Что дальше

Первое — перепроверить MI-DI-FGSM: если после исправления он окажется на уровне PGD, картина по переносу не изменится, но станет непротиворечивой.

Второе — подключить NPR. Третий детектор делает осмысленными и ансамблевые методы, и leave-one-detector-out, и превращает единственную пару в матрицу.

Третье — устранить конфаунд по формату, приведя все изображения к единому контейнеру. Без этого любое утверждение о точности детекторов остаётся под вопросом.